

Claude Opus 5.5 与 Opus 5 能力对比及对课题组的影响评估

项目	内容
编制日期 / 信息截止	2026-09-23
Opus 5.5 发布日期	2026-09-22 (距 Opus 5 发布不足两个月)
数据来源	Anthropic 官方发布页与开发者文档、Artificial Analysis 独立测评 (详见附件)

⚠️ 编制声明：本报告由 Claude Opus 5.5 协助整理，存在“模型评价自己”的偏差风险。为此：① 所有性能数字均取自官方或第三方来源，不凭模型自述；② **主动列出 Opus 5.5 不占优的项目**；③ 对未公开或未核实的信息明确标注。

一、一页结论

#	结论
1	全面强于 Opus 5，且更便宜。 官方 9 项基准全部提升；单价降 20% ，缓存读取降 60% ；官方称典型负载运行成本降约 40% 、输出速度快约 30% 。
2	科学计算能力提升最大，但不是第一。 在最贴近科研场景的 Terminal-Bench-Science 上从 29.0% 翻倍至 58.7% ，但 GPT-6 Astra 为 64.6%，仍领先。
3	新增生物安全分类器，直接触及 AIDD。 相比 Opus 5，新增 bio 类拦截：被判定为“两用生物研究（ 病毒学、毒理学、分子设计 ）”的请求会被拒绝。
4	⚠️ 课题组所在机构大概率无法合规使用。 中国大陆不在 Anthropic 支持地区之列，且官方保留“不向多数所有权归属非支持地区的实体提供服务”的权利。
5	因此对课题组的影响主要是间接的： 竞争水位参照、AIDD 方向上闭源模型可用性收窄的信号、以及评测方法论的借鉴。

二、基本信息对比

项目	Claude Opus 5	Claude Opus 5.5	变化
模型 ID	claude-opus-5	claude-opus-5-5	—
上下文窗口 / 最大输出	1M / 128K tokens	1M / 128K tokens	不变
知识截止	—	2026 年 6 月	—
输入价格 (每百万 token)	\$5	\$4	-20%
输出价格 (每百万 token)	\$25	\$20	-20%
缓存读取	\$0.50	\$0.20	-60%
缓存写入	\$6.25	\$5	-20%
思考 (thinking)	默认开启，可在 high 及以下关闭	始终开启，不可关闭	行为变化

项目	Claude Opus 5	Claude Opus 5.5	变化
默认推理强度（effort）	high	medium	默认下调一档
安全分类器	网络安全（cyber）	网络安全 + 生物（bio） + 推理提取	新增两类

🔴 **effort 默认值的变化容易被忽视**：Opus 5.5 默认 medium，但官方测试中其 medium 已超过 Opus 5 的 high。反过来，同一 effort 档位下 Opus 5.5 思考得更多——沿用 Opus 5 的设置会导致更长的响应和更多 token 消耗。

三、官方基准对比

来源：Anthropic 官方发布页（2026-09-22）。

基准	测什么	Opus 5	Opus 5.5	提升	Fable 5.1	GPT-6 Astra
Terminal-Bench-Science 0.1 ³	真实科研计算工作流	29.0%	58.7%	+29.7	52.6%	64.6% ▲
Terminal-Bench 4.0 ¹	终端环境智能体编程	52.3%	66.4%	+14.1	55.8%	57.9%
AutomationBench ²	业务流程自动化	26.9%	40.0%	+13.1	31.4%	41.4% ▲
CursorBench 4.0	真实代码编辑	46.6%	57.8%	+11.2	51.8%	—
OSWorld 2.0（部分得分）	操作电脑界面	74.0%	81.8%	+7.8	80.7%	—
FrontierCode v1.1	前沿编程难题	48.0%	54.4%	+6.4	50.3%	53.3%
Chartography（含工具）	图表理解	83.4%	89.0%	+5.6	88.4%	—
Humanity's Last Exam（含工具）	跨学科专家级难题	63.6%	67.7%	+4.1	65.6%	57.2%
GDPval-AA v2.1	真实知识工作（Elo）	1708	1846	+138	1735	1542

▲ = 该项 Opus 5.5 并非最高

官方脚注（口径说明，务必注意）：

- Terminal-Bench 4.0：Opus 5.5 用 xhigh 推理强度，GPT-6 Astra 用 high（OpenAI 自报口径）——两者设置不对等；Opus 5.5 标准误 ±2.6 分。
- AutomationBench：由 Zapier 运行，结果计入了安全机制介入导致的失败。
- Terminal-Bench-Science：标准误 ±3.5–5 分；Opus 5.5 的成绩包含被生物/网络安全机制拦截后转交 Opus 4.8 或 Opus 5 完成的实例——即这一项的部分"Opus 5.5 成绩"实际由其他模型完成。

独立第三方测评（Artificial Analysis）

Artificial Analysis 智能指数（Intelligence Index）对 Opus 5.5 各推理强度的评分：

推理强度	low	medium	high	xhigh	max
指数得分	42	51	54	56	58

据其发布，max 档 58 分为该机构测得的最高分；其自测的 Humanity's Last Exam 为 61.4%（与官方含工具口径的 67.7% 设置不同，不可直接比较）。

i 注：Artificial Analysis 原页面因网络限制未能直接访问，以上数字经其公开发布内容的检索摘要获取；Opus 5 在该指数上的对照分数未能核实，故不列出。

四、解读：进步在哪里，没进步在哪里

进步最大的三处

- 1. 科研计算工作流 (+29.7 个百分点，翻倍) ——全表最大提升，也是与课题组最相关的一项（见第五节）。
- 2. 智能体编程与终端操作 (+14.1) ——长链条、多步骤的代码任务明显更可靠。
- 3. 业务流程自动化 (+13.1) ——但仍略低于 GPT-6 Astra。

提升有限的两处

- Humanity's Last Exam (+4.1) 与 FrontierCode (+6.4) ——纯"难题解答"类能力的提升远小于"执行工作流"类能力。
- 一个清晰的模式：这一代的进步主要体现在"把多步骤任务做完"，而非"更聪明地回答单个难题"。

不是第一的地方

基准	Opus 5.5	领先者	差距
Terminal-Bench-Science	58.7%	GPT-6 Astra 64.6%	-5.9
AutomationBench	40.0%	GPT-6 Astra 41.4%	-1.4

📌 对课题组而言，最该记住的是第一行：在最贴近科研场景的基准上，Opus 5.5 **不是**当前最强的模型。

成本：降幅大于标价

官方表述：在许多编程、分析与视觉任务上，Opus 5.5 在默认强度下**以更少 token 达到或超过 Opus 5**，叠加单价下调 20%，因此**"每完成一个任务的成本"降幅显著大于 20%**（官方称典型负载约 40%）。长会话中反复读取缓存的场景节省更多（缓存读取降 60%）。

五、与 AI for Science / 生命科学最相关的三个变化

5.1 科研工作流能力翻倍

Terminal-Bench-Science 由一线科学家贡献的 **70 个真实科研任务**组成，覆盖生命、物理、地球、数学与工程科学。每个任务要求模型在沙箱终端内**真正完成一段科研工作**（信号重建、模型校准、仪器数据处理、统计推断、科学机器学习等），并由**任务作者本人编写的验证测试**判分。

它测的不是"懂不懂教科书知识"，而是**"能不能把一段计算科研工作从头做完"**。Opus 5 → 5.5 在此从 29.0% 升至 58.7%。

5.2 新增生物安全分类器

据 Anthropic 官方开发者文档：

- 相对 Opus 5，生物分类器是新增的；
- 日常健康与教育类问题不受影响；
- 被判定为两用生物研究的请求会被拒绝，官方列举的领域是病毒学、毒理学、分子设计；
- 分类器可能误伤正常请求；拒绝时返回 `stop_reason: "refusal"`，可配置自动转交其他模型重试。

⚠️ "分子设计"与 AIDD 的核心工作直接重叠。官方基准脚注也证实：Opus 5.5 在科研基准上已有部分任务因生物安全机制被转交其他模型完成。

5.3 生命科学验证计划（LSVP）

Anthropic 于 2026-09-17 开放申请，为通过审核的生命科学团队提供放宽生物类安全限制的模型访问：

档位	适用范围	覆盖	续期
Standard Use	大多数生命科学研发工作流（基础研究、研发、临床开发、生产、质控、注册等）	整个团队	每年
High-risk Use	Standard 下仍被拦截的工作；"移除所有拦截生命科学请求的安全机制"	单个研究项目	每六个月

- 面向学术实验室、初创公司、药企等；
- 审核内容：科研资质、安全标准、伦理审查；
- 网络安全类拦截仍然保留；改为离线监控，需保留 30 天数据；
- 公告列出的覆盖模型为 Mythos 5.1、Opus 5、Sonnet 5 及"后续新模型"；Opus 5.5 发布页亦提及该计划。

六、⚠️ 对课题组的可用性：必须先回答的问题

在讨论"对科研的影响"之前，需要先确认能不能用。以下为 Anthropic 官方政策原文要点：

事实	来源
中国大陆不在支持地区列表中（API 与 Claude.ai 均不支持）	Anthropic 支持地区页
香港亦不在列；英国在列	同上
"在法律允许的范围内，Anthropic 保留不向多数直接或间接所有权归属于非支持地区国家的实体提供产品或服务的权利"	同上，政策原文

推论：

1. 课题组所在机构大概率不在 Anthropic 的服务范围内；
2. 第五节的生命科学验证计划，同样很可能不对课题组开放；
3. 身处支持地区（如英国）的成员可合规使用个人账户，但一旦涉及课题组数据，需同时考虑中方数据出境相关规定与Anthropic 的使用政策；
4. 通过非官方渠道访问，既违反服务条款，也存在账号封禁与数据泄露风险——对涉及未发表成果的科研工作，这类风险尤其不可接受。

结论：不建议将 Opus 5.5 作为课题组的生产工具。它对课题组的价值在于**参照**，而非**使用**。

七、对课题组科研的真实影响（间接层面）

对照课题组公开的三大研究方向：

课题组方向	与 Opus 5.5 相关的变化	影响判断
① AI 算法及平台 (大语言模型、生成式智能体、科研助手)	科研工作流自动化能力在不到两个月内翻倍 (29% → 59%)	● 竞争水位显著上移 ——"科研助手/智能体"方向的外部基线需要重新校准
② AIDD 智能药物设计 (小分子、肿瘤疫苗、新抗原、多肽、抗体、核酸药物)	新增生物安全分类器， 分子设计类请求可能被拦截	● 利好自研路线 ——头部闭源模型在 AIDD 核心任务上的可用性正在收窄，自研与开源模型的必要性上升
③ 智能诊疗 (单细胞、多组学、生命科学大模型)	科学数据分析、统计推断、模型拟合类任务能力大幅提升	● 方法论参照 ——可跟踪其能力边界，但因地区限制无法直接作为工具使用

值得展开的一点：评测方法论

Terminal-Bench-Science 的设计思路——**由一线科学家贡献真实任务、由任务作者本人编写验证测试**——解决了"AI for Science 评测只考教科书知识"的问题。该基准**完全开源** (GitHub: `harbor-framework/terminal-bench-science`)，**不依赖任何特定模型，可在本地用任意模型运行**。

这一点对课题组有直接价值：无论使用何种模型，都可以借鉴或直接采用这套评测框架，来衡量自研科研智能体的能力。

八、建议

#	建议	理由
1	不将 Opus 5.5 作为课题组生产工具	地区与实体所有权政策限制；数据合规风险
2	将 Terminal-Bench-Science 纳入科研智能体方向的外部参照	开源、模型无关、可本地运行；Opus 5.5 较 Opus 5 翻倍 (29.0% → 58.7%)，当前最高为 GPT-6 Astra 的 64.6%
3	在 AIDD 方向坚持并加大自研投入	头部闭源模型对分子设计类任务收紧安全限制，差异化空间扩大
4	持续跟踪、定期更新本评估	前沿模型迭代周期已缩短至两个月以内

附录：数据来源与口径

内容	来源
基准对比表、价格、发布日期、安全与对齐声明	Anthropic 官方发布页

内容	来源
生物分类器、effort 默认值、API 行为变化	Anthropic 官方开发者文档（模型迁移指南）
生命科学验证计划	Anthropic 官方公告
科学家支持计划	Anthropic 官方公告
支持地区与实体所有权政策	Anthropic 支持地区页
Terminal-Bench-Science 说明	tbench.ai 官方说明、GitHub 仓库
独立测评	Artificial Analysis（经检索摘要获取，未能直接访问）

口径说明：

- 所有"提升"数值为百分点差（Opus 5.5 – Opus 5），GDPval-AA 为 Elo 分差；
- 不同基准的推理强度与工具设置不同，**跨行不可直接比较**；
- GPT-6 Astra 的数字为 OpenAI 自报、经 Anthropic 发布页转引。

本报告基于公开信息整理，仅供课题组内部交流参考。