



专题报告 · SPECIAL REPORT

Claude Opus 5.5 与 Opus 5

能力对比及对课题组的影响评估

编制日期 / 信息截止

2026-09-23

OPUS 5.5 发布日期

2026-09-22 (距 Opus 5 发布不足两个月)

数据来源

Anthropic 官方发布页与开发者文档、Artificial Analysis 独立测评 (详见附录)

⚠ 编制声明：本报告由 Claude Opus 5.5 协助整理，存在"模型评价自己"的偏差风险。为此：① 所有性能数字均取自官方或第三方来源，不凭模型自述；② **主动列出 Opus 5.5 不占优的项目**；③ 对未公开或未核实的信息明确标注。

一、一页结论

官方基准全部提升

9 / 9

每一项都高于 Opus 5

单价降幅

-20%

缓存读取 -60%

科研工作流基准

29.0 → 58.7%

翻倍；GPT-6 Astra 为 64.6%

课题组可用性

⚠ 受限

中国大陆不在支持地区

1 全面强于 Opus 5，且更便宜。

官方 9 项基准全部提升；单价降 **20%**，缓存读取降 **60%**；官方称典型负载运行成本降本约 **40%**、输出速度快约 **30%**。

2 科学计算能力提升最大，但不是第一。

在最贴近科研场景的 **Terminal-Bench-Science** 上从 29.0% 翻倍至 **58.7%**，但 **GPT-6 Astra** 为 **64.6%**，仍领先。

3 新增生物安全分类器，直接触及 AIDD。

相比 Opus 5，新增 **bio** 类拦截：被判定为"两用生物研究（**病毒学、毒理学、分子设计**）"的请求会被拒绝。

4 课题组所在机构大概率无法合规使用。

中国大陆不在 Anthropic 支持地区之列，且官方保留"不向多数所有权归属非支持地区的实体提供服务"的权利。

5 因此对课题组的影响主要是间接的

竞争水位参照、AIDD 方向上闭源模型可用性收窄的信号、以及评测方法论的借鉴。

二、基本信息对比


项目	Claude Opus 5	Claude Opus 5.5	变化
模型 ID	claude-opus-5	claude-opus-5-5	—
上下文窗口 / 最大输出	1M / 128K tokens	1M / 128K tokens	不变
知识截止	—	2026 年 6 月	—
输入价格（每百万 token）	\$5	\$4	-20%
输出价格（每百万 token）	\$25	\$20	-20%

项目	Claude Opus 5	Claude Opus 5.5	变化
缓存读取	\$0.50	\$0.20	-60%
缓存写入	\$6.25	\$5	-20%
思考 (thinking)	默认开启, 可在 <code>high</code> 及以下关闭	始终开启, 不可关闭	行为变化
默认推理强度 (effort)	<code>high</code>	<code>medium</code>	默认下调一档
安全分类器	网络安全 (<code>cyber</code>)	网络安全 + 生物 (<code>bio</code>) + 推理提取	新增两类

📌 **effort 默认值的变化容易被忽视**：Opus 5.5 默认 `medium`，但官方测试中其 `medium` 已超过 Opus 5 的 `high`。反过来，同一 effort 档位下 Opus 5.5 思考得更多——沿用 Opus 5 的设置会导致更长的响应和更多 token 消耗。

三、官方基准对比

来源：Anthropic 官方发布页（2026-09-22）。



基准	测什么	Opus 5	Opus 5.5	提升	Fable 5.1	GPT-6 Astra
Terminal-Bench-Science 0.1 ³	真实科研计算 workflow	29.0%	58.7%	+29.7	52.6%	64.6% ▲
Terminal-Bench 4.0 ¹	终端环境智能体编程	52.3%	66.4%	+14.1	55.8%	57.9%

基准	测什么	Opus 5	Opus 5.5	提升	Fable 5.1	GPT-6 Astra
AutomationBench ²	业务流程自动化	26.9%	40.0%	+13.1	31.4%	41.4% ▲
CursorBench 4.0	真实代码编辑	46.6%	57.8%	+11.2	51.8%	—
OSWorld 2.0 (部分得分)	操作电脑界面	74.0%	81.8%	+7.8	80.7%	—
FrontierCode v1.1	前沿编程难题	48.0%	54.4%	+6.4	50.3%	53.3%
Chartography (含工具)	图表理解	83.4%	89.0%	+5.6	88.4%	—
Humanity's Last Exam (含工具)	跨学科专家级难题	63.6%	67.7%	+4.1	65.6%	57.2%
GDPval-AA v2.1	真实知识工作 (Elo)	1708	1846	+138	1735	1542

▲ = 该项 Opus 5.5 并非最高

官方脚注 (口径说明, 务必注意) :

- 1. Terminal-Bench 4.0 : Opus 5.5 用 xhigh 推理强度, GPT-6 Astra 用 high (OpenAI 自报口径) ——两者设置不对等; Opus 5.5 标准误 ±2.6 分。
- 2. AutomationBench : 由 Zapier 运行, 结果计入了安全机制介入导致的失败。
- 3. Terminal-Bench-Science : 标准误 ±3.5–5 分; Opus 5.5 的成绩包含被生物/网络安全机制拦截后转交 Opus 4.8 或 Opus 5 完成的实例——即这一项的部分"Opus 5.5 成绩"实际由其他模型完成。

■ 独立第三方测评 (Artificial Analysis)

Artificial Analysis 智能指数 (Intelligence Index) 对 Opus 5.5 各推理强度的评分 :

推理强度	low	medium	high	xhigh	max
指数得分	42	51	54	56	58

据其发布, max 档 58 分为该机构测得的最高分; 其自测的 Humanity's Last Exam 为 61.4% (与官方含工具口径的 67.7% 设置不同, 不可直接比较)。

i 注 : Artificial Analysis 原页面因网络限制未能直接访问, 以上数字经其公开发布内容的检索摘要获取; Opus 5 在该指数上的对照分数未能核实, 故不列出。

四、解读：进步在哪里，没进步在哪里

■ 进步最大的三处

- 1. 科研计算 workflows (+29.7 个百分点, 翻倍) ——全表最大提升, 也是与课题组最相关的一项 (见第五节)。
- 2. 智能体编程与终端操作 (+14.1) ——长链条、多步骤的代码任务明显更可靠。
- 3. 业务流程自动化 (+13.1) ——但仍略低于 GPT-6 Astra。

■ 提升有限的两处

- Humanity's Last Exam (+4.1) 与 FrontierCode (+6.4) ——纯"难题解答"类能力的提升远小于"执行工作流"类能力。
- 一个清晰的模式：这一代的进步主要体现在"把多步骤任务做完"，而非"更聪明地回答单个难题"。

■ 不是第一的地方

基准	Opus 5.5	领先者	差距
Terminal-Bench-Science	58.7%	GPT-6 Astra 64.6%	-5.9
AutomationBench	40.0%	GPT-6 Astra 41.4%	-1.4

🔴 对科研组而言，最该记住的是第一行：在最贴近科研场景的基准上，Opus 5.5 不是当前最强的模型。

■ 成本：降幅大于标价

官方表述：在许多编程、分析与视觉任务上，Opus 5.5 在默认强度下以更少 token 达到或超过 Opus 5，叠加单价下调 20%，因此"每完成一个任务的成本"降幅显著大于 20%（官方称典型负载约 40%）。长会话中反复读取缓存的场景节省更多（缓存读取降 60%）。

五、与 AI for Science / 生命科学最相关的三个变化

■ 5.1 科研工作流程能力翻倍

Terminal-Bench-Science 由一线科学家贡献的 70 个真实科研任务组成，覆盖生命、物理、地球、数学与工程科学。每个任务要求模型在沙箱终端内真正完成一段科研工作（信号重建、模型校准、仪器数据处理、统计推断、科学机器学习等），并由任务作者本人编写的验证测试判分。

它测的不是"懂不懂教科书知识"，而是"能不能把一段计算科研工作从头做完"。Opus 5 → 5.5 在此从 29.0% 升至 58.7%。

■ 5.2 新增生物安全分类器

据 Anthropic 官方开发者文档：

- 相对 Opus 5，生物分类器是新增的；
- 日常健康与教育类问题不受影响；
- 被判定为两用生物研究的请求会被拒绝，官方列举的领域是病毒学、毒理学、分子设计；
- 分类器可能误伤正常请求；拒绝时返回 `stop_reason: "refusal"`，可配置自动转交其他模型重试。

⚠️ "分子设计"与 AIDD 的核心工作直接重叠。官方基准脚注也证实：Opus 5.5 在科研基准上已有部分任务因生物安全机制被转交其他模型完成。

■ 5.3 生命科学验证计划 (LSVP)

Anthropic 于 2026-09-17 开放申请，为通过审核的生命科学团队提供**放宽生物类安全限制**的模型访问：

档位	适用范围	覆盖	续期
Standard Use	大多数生命科学研发工作流（基础研究、研发、临床开发、生产、质控、注册等）	整个团队	每年
High-risk Use	Standard 下仍被拦截的工作；"移除所有拦截生命科学请求的安全机制"	单个研究项目	每六个月

- 面向**学术实验室**、初创公司、药企等；
- 审核内容：科研资质、安全标准、伦理审查；
- 网络安全类拦截**仍然保留**；改为离线监控，需保留 30 天数据；
- 公告列出的覆盖模型为 Mythos 5.1、Opus 5、Sonnet 5 及"后续新模型"；Opus 5.5 发布页亦提及该计划。

六、⚠️ 对课题组的可用性：必须先回答的问题

在讨论"对科研的影响"之前，需要先确认**能不能用**。以下为 Anthropic 官方政策原文要点：

事实	来源
中国大陆不在支持地区列表中（API 与 Claude.ai 均不支持）	Anthropic 支持地区页
香港亦不在列；英国在列	同上
"在法律允许的范围内，Anthropic 保留不向 多数直接或间接所有权归属于非支持地区国家的实体 提供产品或服务的权利"	同上，政策原文

推论：

1. 课题组所在机构**大概率不在 Anthropic 的服务范围内**；
2. 第五节的**生命科学验证计划**，同样很可能**不对课题组开放**；
3. 身处支持地区（如英国）的成员可合规使用个人账户，但**一旦涉及课题组数据**，需同时考虑**中方数据出境相关规定与Anthropic 的使用政策**；
4. 通过非官方渠道访问，既违反服务条款，也存在账号封禁与数据泄露风险——**对涉及未发表成果的科研工作，这类风险尤其不可接受**。

结论：不建议将 Opus 5.5 作为课题组的**生产工具**。它对课题组的价值在于**参照**，而非**使用**。

七、对课题组科研的真实影响（间接层面）

对照课题组公开的三大研究方向：

课题组方向	与 Opus 5.5 相关的变化	影响判断
① AI 算法及平台 (大语言模型、生成式智能体、科研助手)	科研工作流自动化能力在不到两个月内翻倍 (29% → 59%)	● 竞争水位显著上移 ——"科研助手/智能体"方向的外部基线需要重新校准
② AIDD 智能药物设计 (小分子、肿瘤疫苗、新抗原、多肽、抗体、核酸药物)	新增生物安全分类器， 分子设计类请求可能被拦截	● 利好自研路线 ——头部闭源模型在 AIDD 核心任务上的可用性正在收窄，自研与开源模型的必要性上升
③ 智能诊疗 (单细胞、多组学、生命科学大模型)	科学数据分析、统计推断、模型拟合类任务能力大幅提升	● 方法论参照 ——可跟踪其能力边界，但因地区限制无法直接作为工具使用

■ 值得展开的一点：评测方法论

Terminal-Bench-Science 的设计思路——**由一线科学家贡献真实任务、由任务作者本人编写验证测试**——解决了"AI for Science 评测只考教科书知识"的问题。该基准完全开源（GitHub: [harbor-framework/terminal-bench-science](#)），**不依赖任何特定模型，可在本地用任意模型运行**。

这一点对课题组有直接价值：无论使用何种模型，都可以借鉴或直接采用这套评测框架，来衡量自研科研智能体的能力。

八、建议

#	建议	理由
1	不将 Opus 5.5 作为课题组生产工具	地区与实体所有权政策限制；数据合规风险
2	将 Terminal-Bench-Science 纳入科研智能体方向的外部参照	开源、模型无关、可本地运行；Opus 5.5 较 Opus 5 翻倍 (29.0% → 58.7%)，当前最高为 GPT-6 Astra 的 64.6%
3	在 AIDD 方向坚持并加大自研投入	头部闭源模型对分子设计类任务收紧安全限制，差异化空间扩大
4	持续跟踪、定期更新本评估	前沿模型迭代周期已缩短至两个月以内

附录：数据来源与口径

内容	来源
基准对比表、价格、发布日期、安全与对齐声明	Anthropic 官方发布页
生物分类器、effort 默认值、API 行为变化	Anthropic 官方开发者文档（模型迁移指南）
生命科学验证计划	Anthropic 官方公告
科学家支持计划	Anthropic 官方公告
支持地区与实体所有权政策	Anthropic 支持地区页
Terminal-Bench-Science 说明	tbench.ai 官方说明 、 GitHub 仓库
独立测评	Artificial Analysis （经检索摘要获取，未能直接访问）

口径说明：

- 所有"提升"数值为百分点差（Opus 5.5 – Opus 5），GDPval-AA 为 Elo 分差；
- 不同基准的推理强度与工具设置不同，**跨行不可直接比较**；
- GPT-6 Astra 的数字为 OpenAI 自报、经 Anthropic 发布页转引。

本报告基于公开信息整理，仅供课题组内部交流参考。